Prezentacja Projektu

Kosmiczne zagrożenie

Piotr Jakóbczyk
Paweł Litwin
Oliwier Wawrzyniak

EDA

Niezbalansowanie Klas

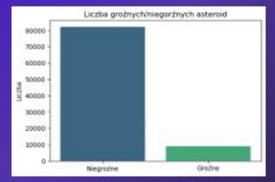

Macierz korelacji

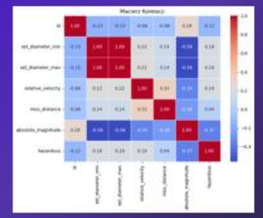

Podsumowanie względem, cech

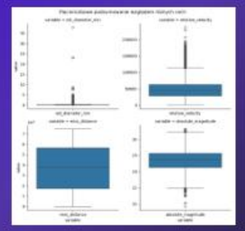

Proporcja zagrożeń względem outlierów

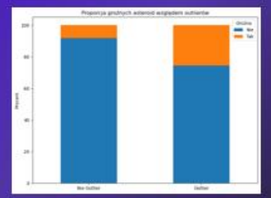

Preprocessing

Usunięcie kolumn:

- "name”,
- "orbiting_body",
- "sentry_object”

Usunięcie kolumny:

- "est_diameter_max"

Usunięcie outlierów pod względem ”est_diameter_min”

Custom Scorer

Nasz system oceny modelu polegał na autorskiej funkcji kosztu przedstawionej wzorem: Koszt = (FP × 1) + (FN × 1 000 000)

```
def custom_score(y_true, y_pred):
    cm = confusion_matrix(y_pred=y_pred, y_true=y_true)
    tn, fp, fn, tp = cm.ravel()
    cost = (fp * 1) + (fn * 10**6)
    return cost

cost_score = make_scorer(custom_score, greater_is_better=False)
```

Proces trenowania modeli

Krok 1

Preprocessing

Usuwamy wybrane kolumny i outlierów

Krok 2

Podział na grupy

Dzielimy na grupy względem id żeby przeciwdziałać wyciekowi danych

Krok 3

GridSearchCV

Używamy GridSearchCV z Sklearn do wybrania najlepszych hiperparametrów i walidacji krzyżowej

Wybrane modele

Regresja logistyczna

SVM

Drzewa decyzyjne

Do oceny każdego modelu została stworzona macierz pomyłek, krzywa PR i krzywa ROC.

Drzewa Decyzyjne

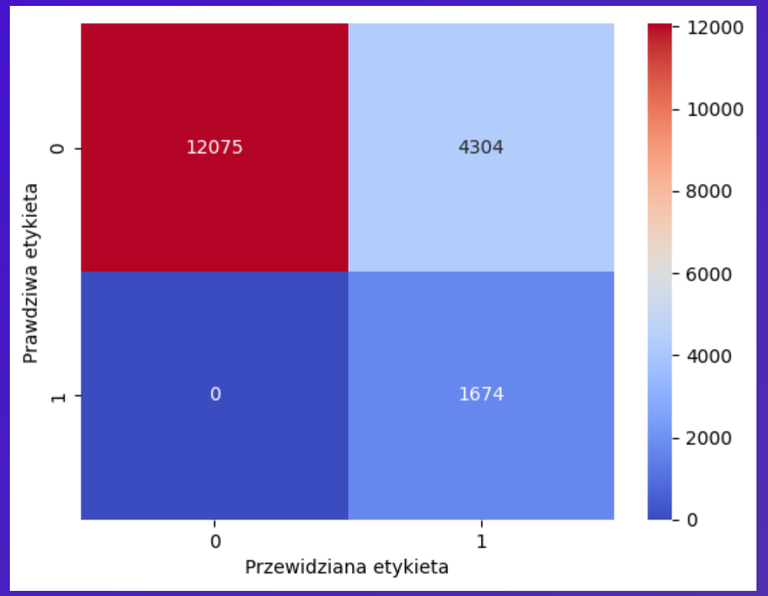

Macierz pomyłek

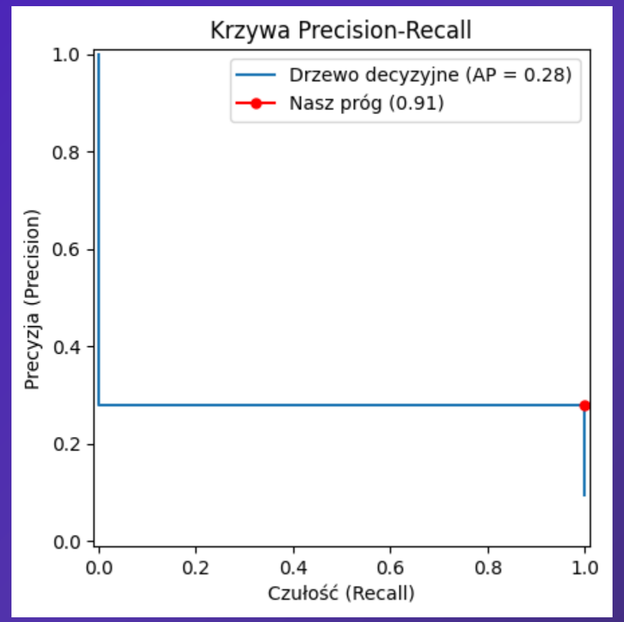

Krzywa PR

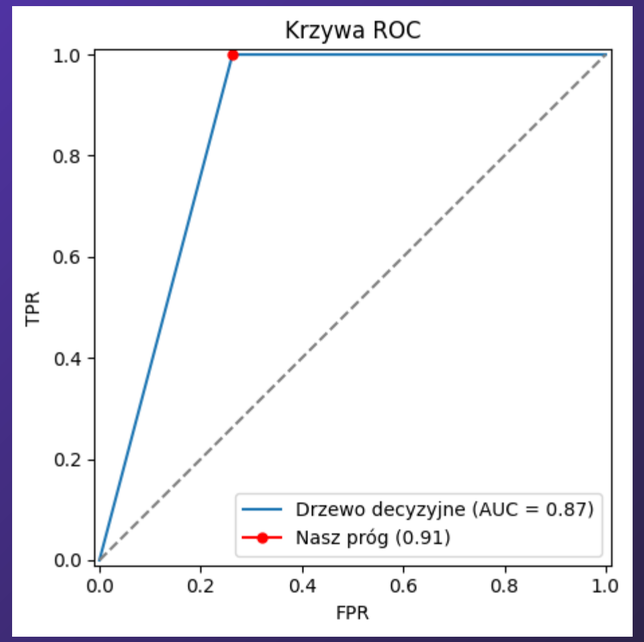

Krzywa ROC

Najlepsze parametry: {'ccp_alpha': 0.01, 'class_weight': {0: 1, 1: 25}, 'max_depth': None}

Regresja logistyczna

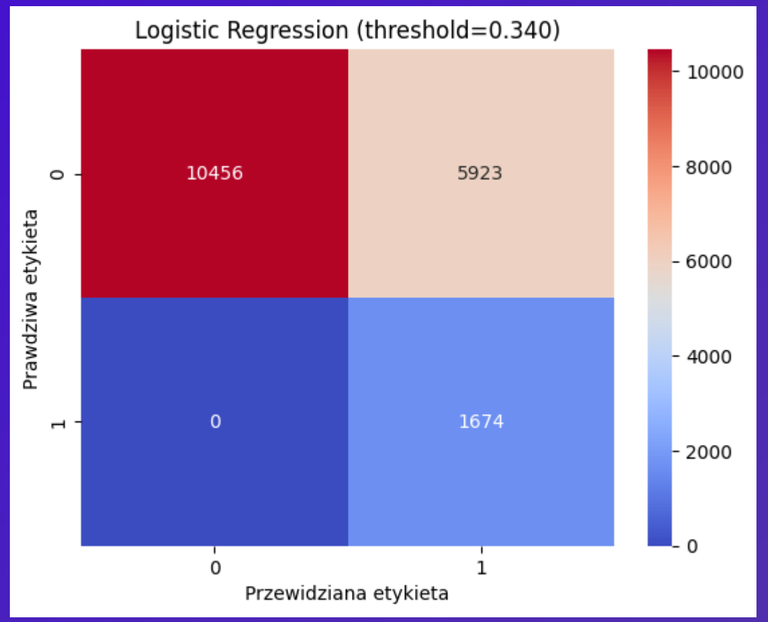

Macierz pomyłek

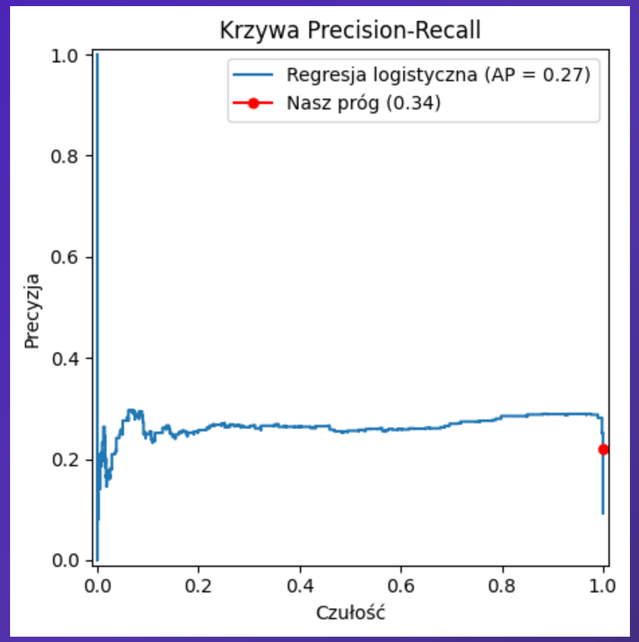

Krzywa PR

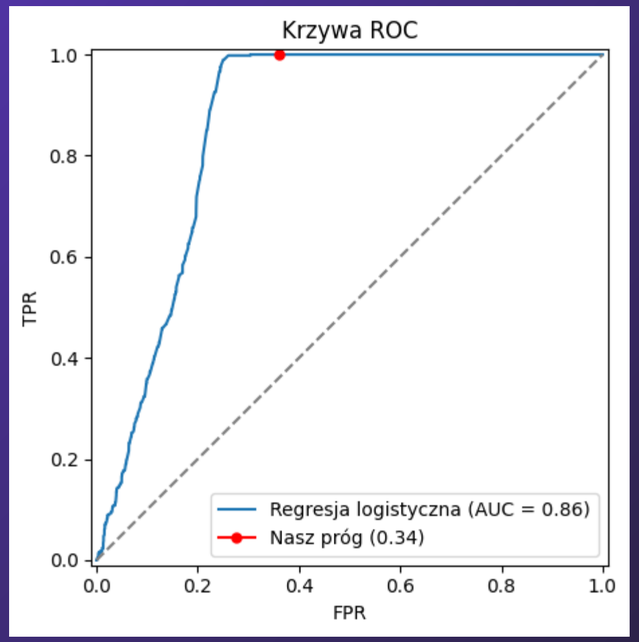

Krzywa ROC

Najlepsze parametry: {'clf__C': 0.001, 'clf__class_weight': 'balanced', 'select__k': 2}
Wybrane cechy: ['est_diameter_min', 'absolute_magnitude']

SVM (Support Vector Machine)

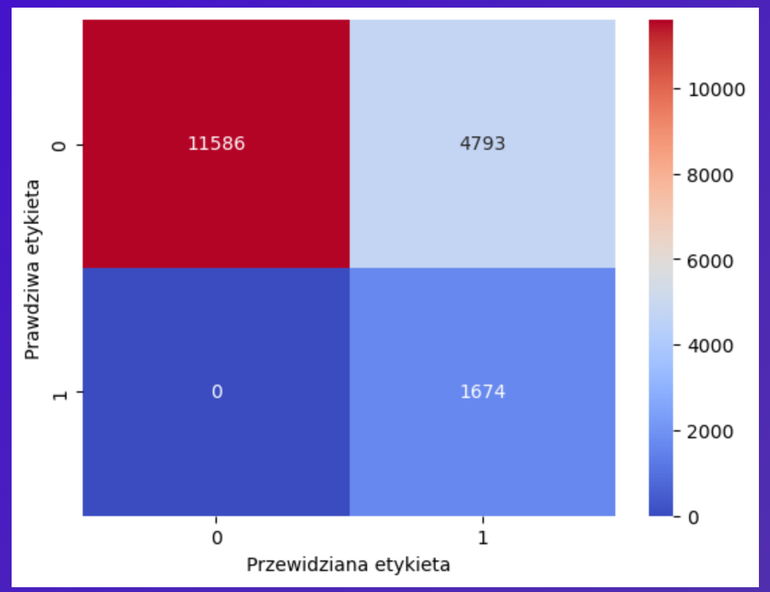

Macierz pomyłek

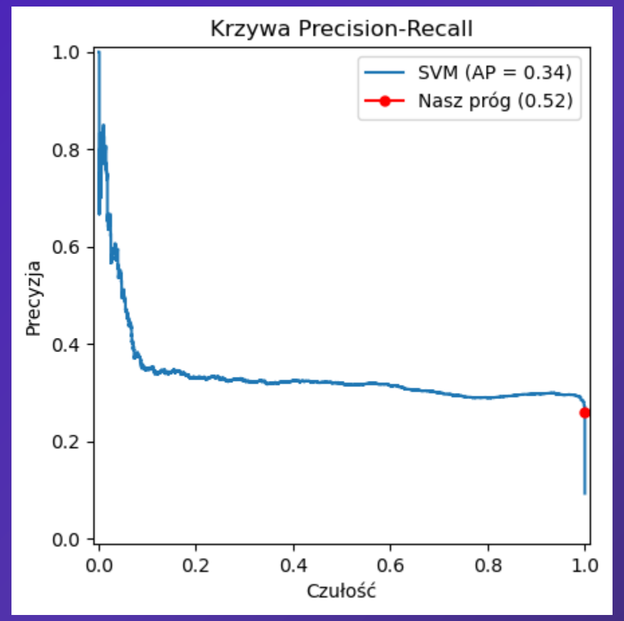

Krzywa PR

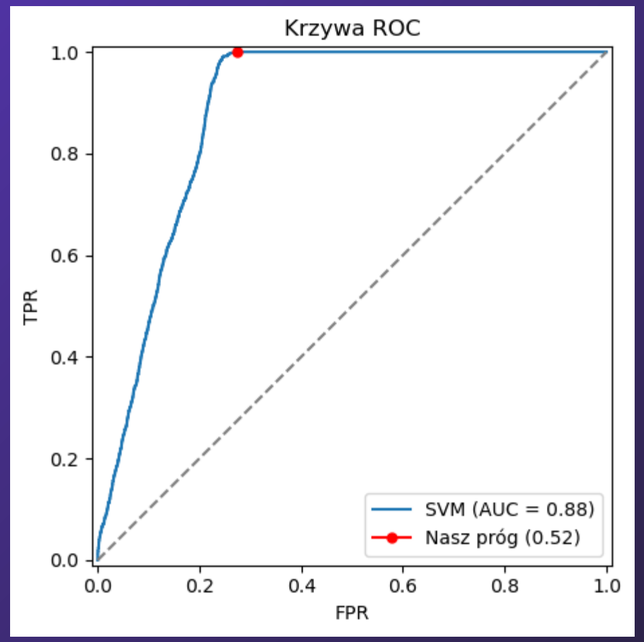

Krzywa ROC

Najlepsze parametry: {'svc__C': 0.01, 'svc__class_weight': {False: 1, True: 100}, 'svc__gamma': 'auto', 'svc__kernel': 'rbf'}

Podział obowiązków

Paweł Litwin:
- EDA
- Preprocessing
- Model Regresji Logistycznej

Piotr Jakóbczyk:
- EDA
- Preprocessing danych
- Model SVM

Oliwier Wawrzyniak:
- Prezentacja
- Custom Scorer
- Model Drzew Decyzyjnych

Pytania?

Dziękujemy za uwagę.

Niezbalansowanie Klas

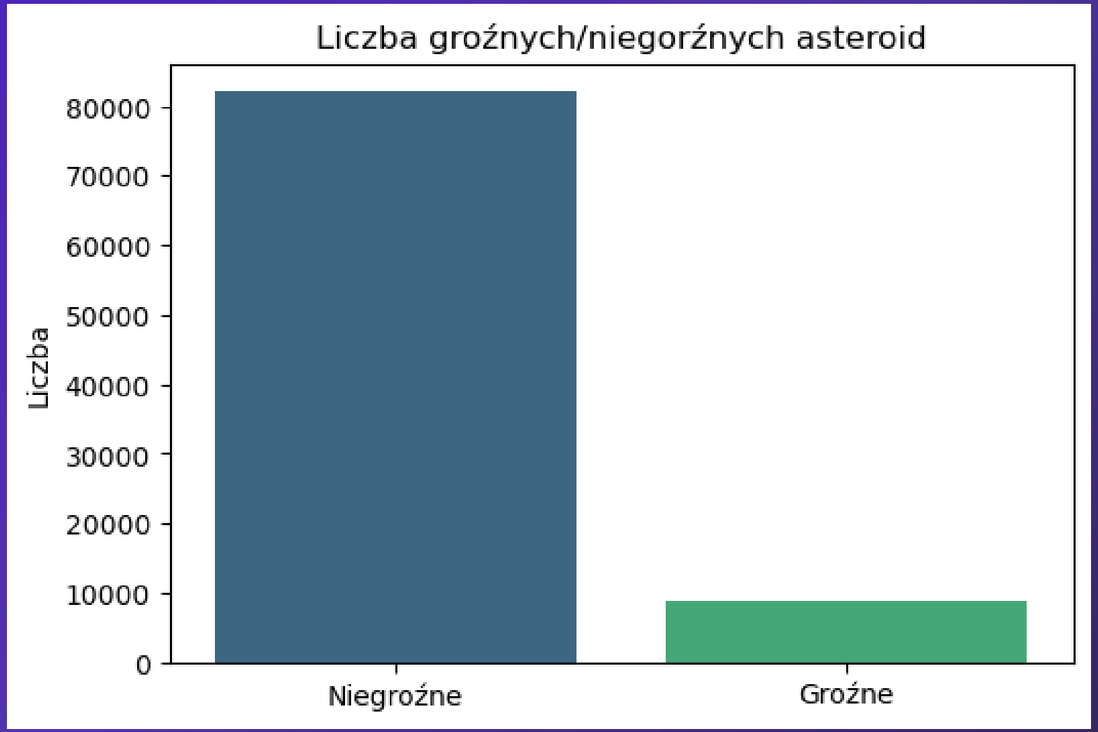

Macierz korelacji

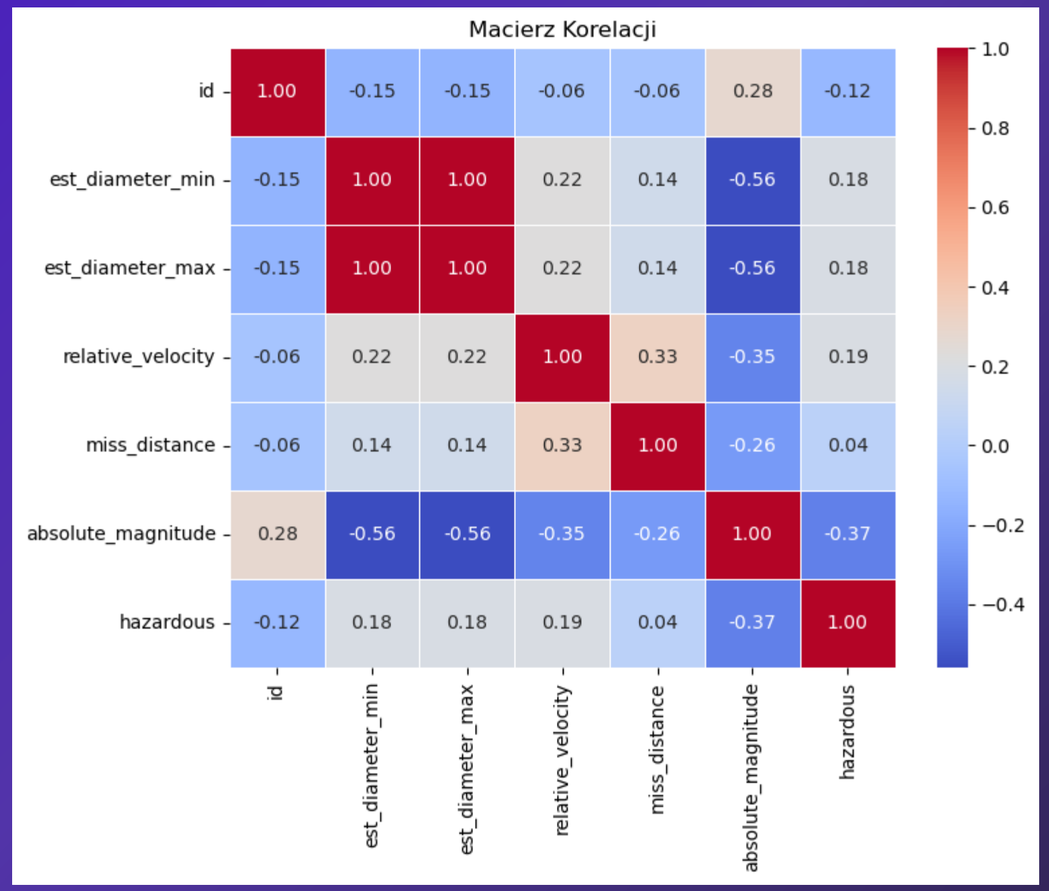

Podsumowanie względem, cech

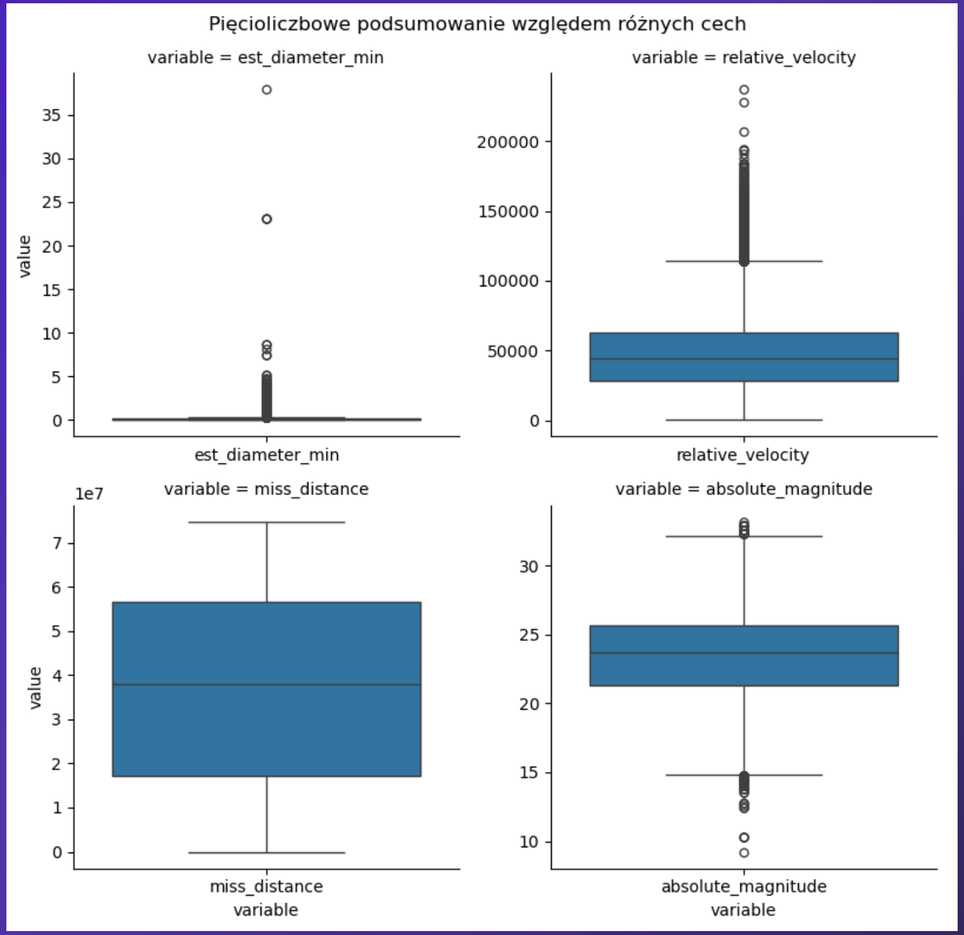
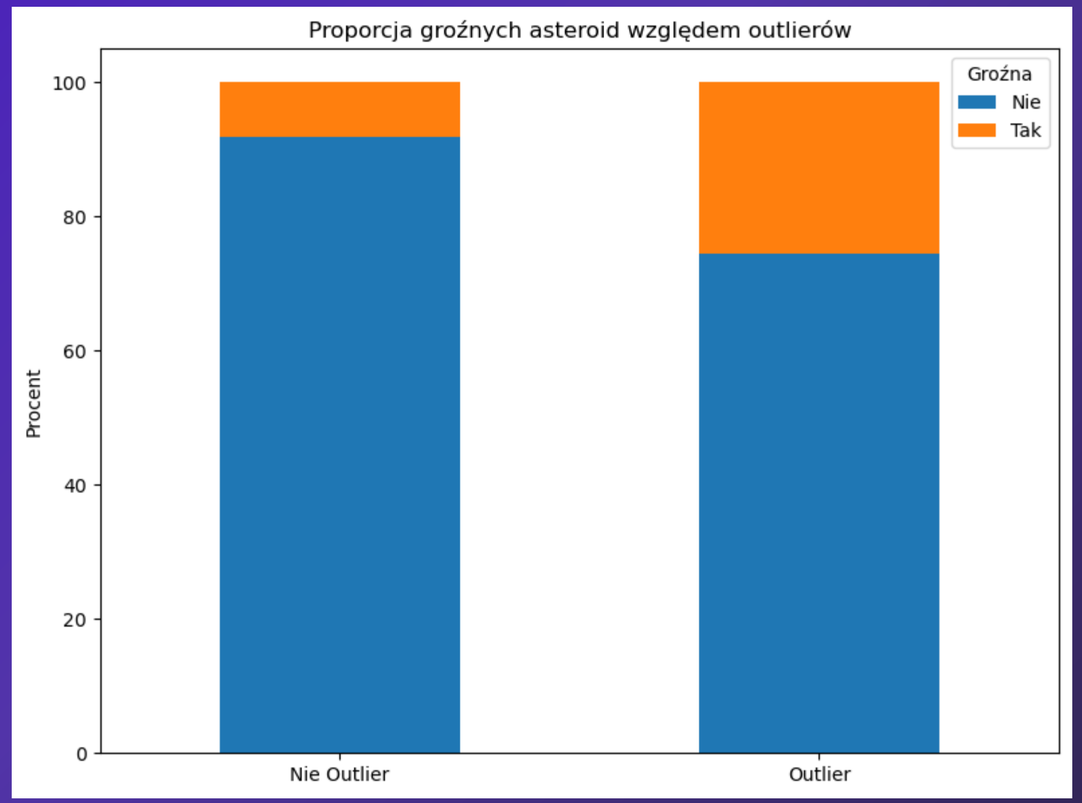
Proporcja zagrożeń względem outlierów